


Modélisation et Résolution des Interactions au sein de l'Espace Aérien par Intelligence Artificielle

Loïc Shi-Garrier

Encadré par

Daniel Delahaye (ENAC) et Nidhal C. Bouaynaya (Rowan University)

30 mai 2022



Extended ATC Planner : concept opérationnel visant à **lier** responsabilités **stratégiques** (équilibrer la demande avec la capacité) et **tactiques** (séparer les avions).


Objectif n°1 : utiliser l'**apprentissage machine** pour **prédire** la **complexité** de l'espace aérien.

Problème : l'apprentissage machine n'est pas **robuste** (au bruit, aux attaques, à des données issues d'une autre distribution ...). Le modèle est incapable de **quantifier son incertitude**.



stop sign
Confidence: 0.9153

+



Adversarial perturbation

=




flowerpot
Confidence: 0.8374

→ **Excès de confiance**, donc problème de **fiabilité** et d'**acceptabilité** auprès de l'utilisateur final, en particulier dans le cadre de **systèmes critiques** comme le contrôle aérien.

Objets d'étude : trajectoires, plans de vol, flux etc. → **séries temporelles**.

Objectif n°2 : étudier la **robustesse** des modèles d'apprentissage machine manipulant des séries temporelles, e.g., **réseaux de neurones récurrents**, **transformers**.



Première approche : Réseaux de neurones bayésiens

- Les **paramètres** du modèle sont des **distributions de probabilités**.
- Les **distributions a posteriori** ne peuvent pas être calculées exactement → Variational Inference, Markov Chain Monte Carlo etc.


Seconde approche : Méthodes probabilistes non bayésiennes

- Méthodes ensemblistes: plusieurs modèles sont entraînés.
- Autres méthodes fondées sur l'optimisation robuste.

Troisième voie : **Approche géométrique**

- Suivre une distribution de probabilité à travers le modèle est difficile.
- En revanche, suivre la **géométrie** des distributions est plus facile.
- La **sortie** du modèle est vue comme une **variable aléatoire** y dont la distribution appartient à une **famille paramétrique** $p(y|\theta)$.
- Cette famille est munie de la **métrique de l'information de Fisher** $G_\theta = \mathbb{E}_\theta[\partial_{\theta_i} \log p(y|\theta) \partial_{\theta_j} \log p(y|\theta)]$ qu'on peut calculer explicitement.
- Le paramètre θ est fourni par le modèle $\theta = N_\omega(x)$. On peut "rétropropager la géométrie" en calculant la **métrique pullback** $G_x = N_\omega^* G_\theta$.
- Le pullback N_ω^* ne dépend que du gradient de N_ω par rapport à x et peut donc être calculé par **rétropropagation**.
- La métrique G_x permet d'étudier **comment le modèle lie l'entrée x à la sortie y** .

- La métrique pullback $G_x = N_\omega^* G_\theta$ est en général **dégénérée** i.e., son noyau est non trivial.
- L'ensemble des noyaux $\ker G_x$ pour chaque x de l'espace d'entrée forme une distribution intégrable \rightarrow on obtient un **feuilletage** $\ker G$ sur l'espace d'entrée.
- Ce feuilletage est intimement lié à la **robustesse** du modèle.



*Source: Tron et al. Canonical foliations of neural networks: application to robustness.

- Supposons que la sortie $y = (y_i)$ soit une **série temporelle** de distribution $p(y|\theta)$ avec $\theta = (\theta_1, \dots, \theta_m)$.
 - D'après le **théorème de Takens**, tout système dynamique $s_{t+1} = \phi(s_t) \in \mathbb{R}^n$ peut être reconstruit à partir d'une seule mesure $\theta_t = f(s_t) \in \mathbb{R}$ suffisamment répétée $(\theta_{t_1}, \dots, \theta_{t_{2n+1}}) = \tilde{\phi}(\theta_{t_0}, \dots, \theta_{t_{2n}})$.
 - Le modèle a pour but de **reconstruire cette dynamique inconnue** $N_\omega \approx \tilde{\phi}$.
 - Ainsi, l'ensemble des trajectoires du système $\tilde{\phi}$ forme un second **feuilletage**.
- L'étude de l'interaction des deux feuilletages permet de caractériser la **robustesse** pour les modèles travaillant sur des **séries temporelles**.

Questions

